

Sistem Rekomendasi Fasilitas Kesehatan Berbasis Ulasan *Google Maps* di Yogyakarta Menggunakan LightGCN

Ikhwan Inzaghi Siswanto¹, Biliarto Sastro Cemerson², Muhammad Goldy Wahyu Haryadi³, Yuniar Indriharsari⁴

¹Fakultas Teknik, Universitas Negeri Yogyakarta, Sleman, 55281, email: ikhwaninzaghi.2020@student.uny.ac.id

²Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri Yogyakarta, Sleman, 55281, email: biliartosastro.2021@student.uny.ac.id

³Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri Yogyakarta, Sleman, 55281, email: muhammadgoldy.2021@student.uny.ac.id

⁴Fakultas Teknik, Universitas Negeri Yogyakarta, Sleman, 55281, email: yuniar@uny.ac.id

Corresponding Author: Ikhwan Inzaghi Siswanto

INTISARI — Akses terhadap fasilitas kesehatan yang tepat menjadi krusial. Penelitian ini mengembangkan sistem rekomendasi untuk fasilitas kesehatan berdasarkan ulasan pengguna di *Google Maps* menggunakan teknologi *Graph Convolutional Networks* (GCN). Tujuan dari penelitian ini adalah untuk meningkatkan akurasi rekomendasi, memberikan rekomendasi yang personal dan relevan, serta mengurangi kompleksitas dan waktu dalam pemilihan fasilitas kesehatan. Metodologi yang digunakan meliputi pengumpulan data ulasan, *preprocessing* data, dan pelatihan model menggunakan LightGCN. Hasil penelitian menunjukkan bahwa model dapat mengumpulkan dan menganalisis 19653 ulasan dari 5851 pengguna, dengan penggunaan *threshold* skor sentimen memberikan hasil yang lebih baik dibandingkan *threshold* rating. Kesimpulannya, penggunaan LightGCN dalam sistem rekomendasi ini berhasil memberikan rekomendasi dengan rating baik (>4) dan jumlah ulasan signifikan (1295 untuk *threshold* rating dan 395 untuk *threshold* sentiment score) dan meningkatkan kualitas rekomendasi fasilitas kesehatan yang lebih akurat dan relevan, dengan potensi pengembangan lebih lanjut untuk peningkatan sistem.

KATA KUNCI — Sistem Rekomendasi, Fasilitas Kesehatan, *Graph Convolutional Networks*, *Google Maps*.

I. PENDAHULUAN

Informasi mengenai fasilitas kesehatan dapat ditemukan dengan mudah melalui *platform online* seperti *Google Maps*. Ulasan pengguna yang terdapat dalam *platform* ini tidak hanya memberikan gambaran tentang kualitas pelayanan fasilitas kesehatan, tetapi juga mencerminkan pengalaman nyata para pengguna (Tony dkk, 2022). Meningkatnya jumlah ulasan pengguna ini menawarkan potensi besar untuk digunakan dalam pengembangan sistem rekomendasi yang dapat mempermudah masyarakat dalam memilih fasilitas kesehatan yang sesuai dengan kebutuhan mereka.

Sistem rekomendasi adalah metode yang membantu pengguna membuat keputusan dalam lingkungan informasi yang kompleks [1]. Sistem rekomendasi telah banyak digunakan dalam berbagai bidang seperti film, berita, dan produk. Sistem rekomendasi membantu pengguna dalam menemukan informasi yang relevan dan sesuai dengan preferensi mereka. Menurut [2], hampir 95% konsumen di Indonesia menggunakan ponsel mereka untuk mencari informasi tentang produk dan layanan secara *online* sebelum menggunakannya. Hal ini menunjukkan pentingnya sistem rekomendasi dalam membantu konsumen membuat keputusan yang lebih informatif dan efisien.

Provinsi Daerah Istimewa Yogyakarta, sebagai salah satu provinsi destinasi wisata dan pendidikan utama di Indonesia, keberadaan fasilitas kesehatan yang berkualitas dan mudah diakses menjadi krusial. Namun, dalam menghadapi beragam pilihan, tantangan utama bagi masyarakat adalah memilih fasilitas kesehatan yang memenuhi standar kualitas yang diharapkan. Untuk mengatasi tantangan ini, pendekatan yang inovatif dalam memanfaatkan ulasan pengguna dari *Google Maps* menjadi relevan.

Teknik-teknik sistem rekomendasi telah berkembang pesat, seperti *content-based filtering*, *collaborative filtering* dan *hybrid filtering* [3]. Dalam teknik *content based filtering*, rekomendasi dibuat berdasarkan profil pengguna menggunakan fitur-fitur yang diekstraksi dari konten item yang telah dievaluasi pengguna di masa lalu. Item yang memiliki keterkaitan tinggi

dengan item yang mendapat rating positif kemudian direkomendasikan kepada pengguna [4]. Teknik *collaborative filtering* bekerja dengan membangun database (*matriks user-item*) preferensi untuk item oleh pengguna, kemudian mencocokkan pengguna dengan minat dan preferensi yang relevan dengan menghitung kemiripan antara profil mereka untuk membuat rekomendasi [5]. Sedangkan teknik *hybrid filtering* adalah kombinasi dari dua atau lebih teknik yang digunakan secara bersama-sama untuk mengatasi keterbatasan teknik rekomendasi individu [6].

Pada beberapa tahun terakhir, pendekatan berbasis *Graph Convolutional Network* (GCN) telah menjadi pengembangan baru untuk sistem rekomendasi dengan teknik *collaborative filtering* [7]. Penelitian-penelitian sebelumnya menunjukkan bahwa GCN dapat digunakan dalam berbagai aplikasi sistem rekomendasi karena kemampuan uniknya dalam menangkap hubungan kompleks antara pengguna dan item melalui representasi *graph*. Penelitian oleh [8] menggunakan GCN pada sistem rekomendasi *e-learning* menunjukkan bahwa hasil evaluasi model GCN mengungguli sistem rekomendasi *content-based filtering* dan *collaborative filtering* yang ada. Penelitian lain dalam sistem rekomendasi artikel ilmiah menunjukkan bahwa model *Content Attention Heterogeneous Graph* (CAH) secara signifikan lebih baik daripada metode rekomendasi *content-based* dalam hal efek rekomendasi [9]. Dengan menggabungkan informasi struktur graf dan fitur item, GCN memberikan kemampuan untuk memahami preferensi pengguna dengan lebih baik, sehingga meningkatkan akurasi rekomendasi.

Salah satu model GCN yang menjanjikan adalah *Light Graph Convolutional Network* (LightGCN). Penelitian terdahulu yang dilakukan oleh [10] dalam sistem rekomendasi perjalanan menunjukkan bahwa LightGCN memiliki kinerja yang lebih baik dibandingkan model *Matrix Factorization*, dengan peningkatan sebesar 167% dalam *precision*, 203% dalam *recall*, dan 98,6% dalam NDCG untuk rekomendasi perjalanan atau tempat. Penelitian lain oleh [7] juga

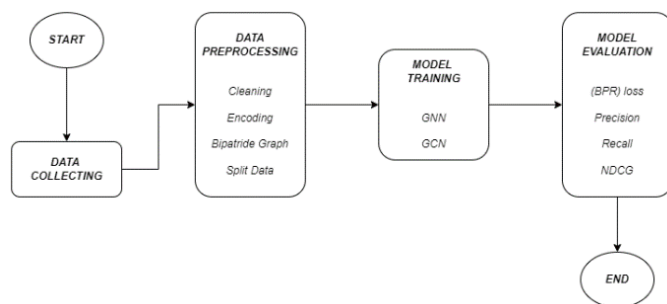
menunjukkan bahwa model LightGCN unggul dibandingkan dengan *Neural Graph Collaborative Filtering* (NGCF), dengan peningkatan yang signifikan sekitar 16,0% secara relatif dalam kualitas rekomendasi.

Berdasarkan uraian tersebut, maka penelitian ini bertujuan untuk mengembangkan sistem rekomendasi fasilitas kesehatan berbasis ulasan *Google Maps* menggunakan LightGCN. LightGCN dipilih karena kemampuannya dalam menghadapi skala besar data dan mempertahankan kualitas rekomendasi tanpa kompleksitas komputasi yang berlebihan [7]. Penelitian ini diharapkan dapat memberikan kontribusi signifikan dalam mengatasi beberapa tantangan yang ada dalam sistem rekomendasi konvensional, seperti skalabilitas dengan jumlah data yang besar dan kompleksitas dalam menangani ulasan yang subjektif serta sering kali ambigu.

Manfaat utama dari penelitian ini adalah peningkatan aksesibilitas informasi terkait fasilitas kesehatan di Provinsi Daerah Istimewa Yogyakarta, memungkinkan masyarakat untuk membuat keputusan yang lebih informasi tentang layanan kesehatan berdasarkan ulasan pengguna yang terstruktur. Namun, penelitian ini memiliki batasan, termasuk penggunaan data ulasan yang terbatas hanya dari *platform Google Maps* dan fokus eksklusif pada fasilitas kesehatan di Provinsi Daerah Istimewa Yogyakarta. Hal ini membatasi kemampuan untuk menggeneralisasi temuan penelitian ke wilayah atau *platform* ulasan lainnya.

II. METODE PENELITIAN

Tahapan penelitian ini ditampilkan dalam bentuk diagram alir pada Gambar 1. Penelitian akan menggunakan model *Light Graph Convolutional Network* (Light GCN) untuk memberikan rekomendasi fasilitas kesehatan di Provinsi Daerah Istimewa Yogyakarta berdasarkan ulasan pengguna pada *platform Google Maps*. Data yang telah diperoleh kemudian dilakukan *preprocessing*, yang meliputi *cleaning*, *encoding*, pembuatan *bipartite graph*, serta *split data*.



Gambar 1. Tahapan Penelitian

Setelah *preprocessing*, tahap selanjutnya adalah pelatihan dan evaluasi model LightGCN. *Loss function* yang digunakan dalam melakukan proses evaluasi baik pada data validasi dan uji adalah *Bayesian Personalized Ranking* (BPR) *loss* dengan metrik evaluasi *recall*, *precision* dan *Normalized Discounted Cumulative Gain* (NDCG).

A. DATA COLLECTING

Data yang digunakan dalam penelitian ini berasal dari ulasan pengguna di *platform Google Maps*, yang dikumpulkan menggunakan dua metode, yakni *crawling* otomatis dan manual dengan menggunakan bahasa pemrograman *Python*. *Crawling* data otomatis memanfaatkan *Google Maps Place API*, namun terbatas hanya pada 10 ulasan terbaru dan 10 ulasan relevan

terhadap fasilitas kesehatan. Untuk mengatasi batasan ini, *crawling* data secara manual dilakukan dengan menggunakan pustaka *Selenium*.

Setelah proses pengumpulan data selesai, kami berhasil mengumpulkan data dari sejumlah besar ulasan pengguna *Google Maps* yang terkait dengan fasilitas kesehatan di Provinsi Daerah Istimewa Yogyakarta. Total ulasan yang berhasil dikumpulkan mencapai 19653 ulasan, yang tersebar di 138 tempat fasilitas kesehatan. Data ini berasal dari kontribusi 5851 pengguna yang memberikan ulasan. Rincian distribusi rating dari ulasan yang dikumpulkan dapat dilihat pada Tabel I.

TABEL I
SEBARAN RATING PADA ULASAN

Rating	Jumlah Ulasan
1	3.920
2	1.089
3	1.123
4	1.975
5	11.546

B. DATA PREPROCESSING


Proses *preprocessing* bertujuan untuk mentransformasikan data mentah ke dalam format yang lebih bersih dan siap digunakan untuk analisis lebih lanjut. Tahapan pertama yang dilakukan adalah *cleaning*, yang mencakup penghapusan emoji, penghapusan simbol yang tidak jelas, dan penanganan terhadap pengguna yang tidak memberikan ulasan. Langkah-langkah ini diperlukan untuk memastikan konsistensi dan kebersihan data, sehingga algoritma analisis dapat menghasilkan hasil yang lebih akurat dan dapat dipercaya.

Setelah tahapan *cleaning* selesai, langkah berikutnya adalah melakukan *encoding* pada fasilitas kesehatan dan pengguna. *Encoding* dilakukan untuk mengubah entitas fasilitas kesehatan dan pengguna ke dalam representasi numerik yang dapat diproses oleh model. Selanjutnya, representasi vektor dari teks ulasan pengguna dibuat menggunakan model berbasis *Bidirectional Encoder Representations from Transformers* (BERT). Representasi ini memungkinkan algoritma untuk memahami konteks dan makna dari teks ulasan secara lebih mendalam.

Tahapan selanjutnya adalah membangun *bipartite graph* yang menghubungkan *node* pengguna dan *node* fasilitas kesehatan. *Edges* dalam *graph* ini menggambarkan hubungan antara pengguna dan fasilitas kesehatan berdasarkan rating yang diberikan dan teks ulasan yang ditulis. Pembangunan *bipartite graph* ini penting untuk merepresentasikan struktur data yang akan digunakan oleh model LightGCN. Terakhir, data yang sudah melewati proses *preprocessing* akan dibagi menjadi tiga bagian: data latih, data validasi, dan data uji dengan rasio pembagian 8:1:1.

C. PELATIHAN MODEL

Dalam tahap ini akan dilakukan beberapa langkah utama yang mencakup pembuatan, dan pelatihan model. Model yang bangun adalah Light GCN. Kami menggunakan pustaka *PyTorch Geometric* untuk melakukan implementasi model Light GCN. Gambaran arsitektur model Light GCN ditampilkan pada Gambar 2.



Gambar 2. Gambar Arsitektur Model Light GCN (Sumber: [7])

D. EVALUASI MODEL

Evaluasi model akan dilakukan pada proses pelatihan menggunakan data validasi yang nantinya akan digunakan untuk melakukan *parameters update* dan juga proses evaluasi yang dilakukan setelah proses pelatihan selesai menggunakan data uji. *Loss function* yang digunakan dalam melakukan proses evaluasi baik dengan data validasi dan uji adalah *Bayesian Personalized Ranking (BPR) loss* dengan metrik evaluasi *recall*, *precision* dan *Normalized Discounted Cumulative Gain (NDCG)*.

Bayesian Personalized Ranking (BPR) loss merupakan suatu fungsi kerugian yang secara luas diaplikasikan dalam sistem rekomendasi, khususnya untuk tugas pengurutan preferensi secara relatif antar item. BPR adalah metode yang dirancang untuk memodelkan preferensi relatif antar pasangan item dalam sebuah dataset. Pendekatan ini bertujuan untuk memaksimalkan preferensi terhadap item yang telah dipilih pengguna dibandingkan dengan item yang tidak mereka pilih, dengan tujuan mengoptimalkan urutan dalam rekomendasi yang diberikan.

Fungsi *loss* BPR didasarkan pada asumsi bahwa pengguna lebih menyukai item yang mereka interaksi dibandingkan dengan item yang belum mereka interaksi. Tujuan dari optimasi fungsi ini adalah untuk meminimalkan nilai *BPR loss*, yang secara matematis tertulis pada (1) [11].

$$L_{BPR} = - \sum_{w=1}^M \sum_{i \in N_w} \sum_{j \notin N_w} \ln \sigma(\hat{y}_{wi} - \hat{y}_{wj}) + \lambda \|E^{(0)}\|^2 \quad (1)$$

Di mana λ menunjukkan koefisien *L2* yang digunakan untuk regularisasi.

Dalam evaluasi performa model, metrik yang digunakan bersamaan dengan *BPR loss* meliputi *Recall*, *Precision*, dan *Normalized Discounted Cumulative Gain (NDCG)*. *Recall* dan *precision* digunakan untuk mengukur kinerja sistem. *Recall* merupakan tingkat keberhasilan sistem dalam menemukan kembali sebuah informasi. Metode evaluasi ini mengukur proporsi item relevan yang berhasil direkomendasikan oleh model dari total item yang seharusnya direkomendasikan. Sedangkan, *precision* adalah kecocokan antara bagian data yang diambil dengan informasi yang dibutuhkan. Metode evaluasi ini mengukur efektivitas model dalam merekomendasikan item relevan dari total rekomendasi yang diberikan [11]. Berikut adalah persamaan dari *Precision* dan *Recall* berturut-turut pada (2) dan (3).

$$Precision@K(u) = \frac{|R^k(u) \cap T(u)|}{K} \quad (2)$$

$$Recall@K(u) = \frac{|R^k(u) \cap T(u)|}{|T(u)|} \quad (3)$$

Dimana $T(u)$ menunjukkan kumpulan proyek kebenaran dasar, $K(u)$ menunjukkan kumpulan proyek K teratas yang direkomendasikan.

NDCG adalah metrik yang mengukur kualitas rangkaian rekomendasi dengan memberikan bobot lebih pada rekomendasi yang berada di posisi atas. *NDCG* memperhitungkan posisi pemeringkatan proyek, yang tidak dipertimbangkan dalam tiga posisi metrik sebelumnya. *NDCG* didapatkan menggunakan persamaan pada (4).

$$NDCG@K = \frac{1}{|U|} \sum_{u \in U} \frac{\sum_{k=1}^K \frac{I(R_k^k(u) \in T(u))}{\log(k+1)}}{\sum_{k=1}^K \frac{1}{\log(k+1)}} \quad (4)$$

Dimana $R^k(u)$ adalah k^{th} item ke- l di kumpulan item yang direkomendasikan K teratas $R^k(u)$ [11].

III. HASIL DAN PEMBAHASAN

Dalam pengembangan sistem rekomendasi fasilitas kesehatan menggunakan model *LightGCN*, kami menggunakan dua pengaturan *threshold* yaitu dengan menggunakan *rating threshold* dan *sentiment score threshold*. Hasil evaluasi dengan jumlah *layer* yang berbeda ditunjukkan pada Tabel II dan Tabel III.

TABEL II
HASIL EVALUASI MODEL DENGAN *RATING THRESHOLD*

Metrik Evaluasi	2 Layer	3 Layer	4 Layer
<i>test_loss</i>	0,00	0,00	0,00
<i>test_recall@20</i>	0,36	0,35	0,36
<i>test_precision@20</i>	0,02	0,01	0,01
<i>test_ndcg@20</i>	0,13	0,12	0,13

TABEL III
HASIL EVALUASI MODEL DENGAN *SENTIMEN SCORE THRESHOLD*

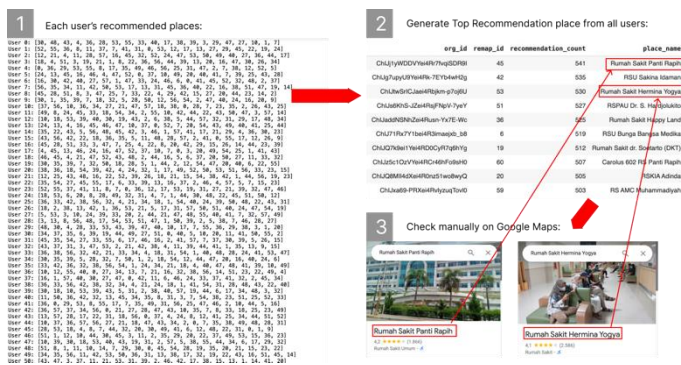
Metrik Evaluasi	2 Layer	3 Layer	4 Layer
<i>test_loss</i>	0,00	0,00	0,00
<i>test_recall@20</i>	0,37	0,39	0,37
<i>test_precision@20</i>	0,12	0,02	0,02
<i>test_ndcg@20</i>	0,14	0,15	0,14

Pada Tabel II, hasil evaluasi model dengan *rating threshold* menunjukkan bahwa semua model dengan jumlah *layer* yang berbeda (2, 3, dan 4 *layer*) memiliki nilai *test_loss* yang sangat rendah, yakni 0,00. Namun demikian, terdapat perbedaan pada nilai *recall@20*, *precision@20*, dan *NDCG@20* antara ketiga model tersebut. Model dengan 2 dan 4 *layer* menghasilkan nilai *recall@20* dan *precision@20* yang lebih tinggi dibandingkan dengan model 3 *layer*, meskipun perbedaannya relatif kecil. Hasil ini menunjukkan bahwa dalam konteks penggunaan *rating threshold*, model dengan 2 atau 4 *layer* cenderung memberikan rekomendasi yang sedikit lebih akurat dalam hal mencari

kembali item yang relevan (*recall*) dan keakuratan rekomendasi (*precision*), dibandingkan dengan model 3 layer.

Pada Tabel III, model dengan *sentiment score threshold* menunjukkan performa yang lebih baik secara keseluruhan. Model dengan 3 layer memberikan hasil terbaik dengan *test loss* sebesar 0,00, *recall@20* sebesar 0,39, *precision@20* sebesar 0,02, dan *NDCG@20* sebesar 0,15. Ini menunjukkan bahwa penggunaan *sentiment score threshold* dapat memberikan peningkatan yang signifikan dalam akurasi dan relevansi rekomendasi.

Setelah tahapan evaluasi model, dilakukan *Real World Evaluation* dengan alur yang dijelaskan pada Gambar 4. Rekomendasi yang dikembangkan dievaluasi menggunakan data yang diperoleh dari lingkungan nyata atau pengguna yang sebenarnya. Evaluasi ini bertujuan untuk mengukur sejauh mana kinerja model saat diterapkan dalam kondisi yang sesungguhnya.



Gambar 4. Real World Evaluation process

Setiap pengguna akan mendapatkan beberapa rekomendasi tempat yang sesuai berdasarkan data yang dikumpulkan. Selanjutnya, dilakukan perhitungan rekomendasi yang diberikan pada setiap pengguna berdasarkan *remap_id* (ID tempat) untuk menghasilkan ID yang memiliki jumlah rekomendasi terbanyak. Setelah mendapatkan rekomendasi teratas, akan dilakukan verifikasi manual pada Google Maps untuk mengetahui rating yang sebenarnya dan memberikan penilaian apakah hasil rekomendasi tersebut sesuai dengan rating yang ada. Berikut merupakan hasil *generate top* berdasarkan rating *threshold* dan *sentiment score threshold*.

TABEL IV
TOP 5 REKOMENDASI (RATING THRESHOLD)

No	Nama Tempat	Rating	Jumlah Ulasan
1	RS Pantj Rapih	4,2	1.886
2	RSU Sakina Idaman	4,2	1.811
3	RS Hermina Yogya	4,1	2.586
4	RSPAU Dr. S. Hardjolukito	4,6	2.565
5	RS Happy Land	3,9	885

TABEL V
TOP 5 REKOMENDASI (SENTIMENT SCORE TRESHOLD)

No	Nama Tempat	Rating	Jumlah Ulasan
1	RSK Bedah Sinduadi	4,0	103
2	Klinik Medikatama Jogja	4,6	68
3	RSU Sakina Idaman	4,2	1.811
4	Klinik Pratama Realino	4,6	142
5	RSI Hidayatullah	3,6	948

IV. KESIMPULAN

Penelitian ini berhasil mengembangkan sistem rekomendasi fasilitas kesehatan dengan menggunakan ulasan pengguna di

Google Maps melalui model LightGCN. Implementasi penggunaan model LightGCN berhasil memberikan rekomendasi yang kebanyakan memiliki rating baik (>4 rating) dengan jumlah rata rata ulasan sebanyak 1.295 untuk model yang menggunakan rating *threshold* dan 395 untuk *sentiment score threshold*. Hal ini menunjukkan rekomendasi tempat yang dihasilkan oleh sistem dengan model LightGCN dapat diterima. Tujuan penelitian untuk meningkatkan akurasi rekomendasi, menyediakan rekomendasi yang personal dan relevan, serta mengurangi kompleksitas pemilihan fasilitas kesehatan telah tercapai. Dari hasil crawling, kami berhasil mengumpulkan 19653 ulasan dari 5851 pengguna terkait 138 fasilitas kesehatan di Provinsi Daerah Istimewa Yogyakarta. Evaluasi model menggunakan dua pengaturan *threshold* menunjukkan bahwa penggunaan *sentiment score threshold* memberikan hasil terbaik.

Pada konfigurasi model dengan 3 layer, LightGCN menunjukkan performa terbaik dengan *test loss* sebesar 0,00, *recall@20* sebesar 0,39, *precision@20* sebesar 0,02, dan *NDCG@20* sebesar 0,15. Hasil ini mengindikasikan bahwa model mampu memberikan rekomendasi yang lebih akurat dan relevan dibandingkan model lain. Penggunaan *sentiment score threshold* terbukti lebih efektif dibandingkan *rating threshold*, menunjukkan pentingnya analisis sentimen dalam meningkatkan kualitas rekomendasi. Konfigurasi pelatihan yang digunakan mencakup parameter seperti *batch size* sebesar 2048, *learning rate* 0,001, dan penggunaan 3 layer dalam LightGCN, yang semuanya berkontribusi pada performa optimal model.

Untuk pengembangan lebih lanjut, disarankan untuk memperluas cakupan data dengan mengumpulkan ulasan dari berbagai platform selain *Google Maps* guna memperkaya dataset dan meningkatkan akurasi rekomendasi. Penelitian selanjutnya dapat menggabungkan metode kolaboratif dan konten untuk meningkatkan personalisasi rekomendasi. Selain itu, eksplorasi model yang lebih kompleks seperti *variational autoencoders* (VAE) atau *reinforcement learning* dapat dipertimbangkan untuk meningkatkan performa sistem. Implementasi pada skala yang lebih luas juga dianjurkan, untuk menguji generalisasi model di berbagai daerah dan mengidentifikasi potensi perbaikan berdasarkan variasi data demografis dan geografis. Dengan demikian, sistem rekomendasi dapat menjadi alat yang lebih efektif dalam membantu pengguna memilih fasilitas kesehatan yang tepat sesuai dengan kebutuhan mereka.

REFERENSI

- [1] F. O. Isinkaye, Y. O. Folajimi, dan B. A. Ojokoh, "Recommendation Systems: Principles, Methods and Evaluation," *Egyptian Informatics Journal*, vol. 16, no. 3, hlm. 261–273, Nov 2015, doi: 10.1016/j.eij.2015.06.005.
- [2] Y. Debora, "Berapa Besar Pengaruh Ulasan Pembeli Saat Berbelanja Online?," *Tirto.id*.
- [3] D. Roy dan M. Dutta, "A Systematic Review and Research Perspective on Recommender Systems," *J Big Data*, vol. 9, no. 1, hlm. 59, Des 2022, doi: 10.1186/s40537-022-00592-5.
- [4] J. Bobadilla, F. Ortega, A. Hernando, dan A. Gutiérrez, "Recommender Systems Survey," *Knowl Based Syst*, vol. 46, hlm. 109–132, Jul 2013, doi: 10.1016/j.knsys.2013.03.012.
- [5] J. L. Herlocker, J. A. Konstan, L. G. Terveen, dan J. T. Riedl, "Evaluating Collaborative Filtering Recommender Systems," *ACM Trans Inf Syst*, vol. 22, no. 1, hlm. 5–53, Jan 2004, doi: 10.1145/963770.963772.
- [6] R. Burke, "Hybrid Recommender Systems: Survey and Experiments," *User Model User-adapt Interact*, vol. 12, no. 4, hlm. 331–370, 2002, doi: 10.1023/A:1021240730564.
- [7] X. He, K. Deng, X. Wang, Y. Li, Y. Zhang, dan M. Wang, "LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation," dalam *Proceedings of the 43rd International ACM*

SIGIR Conference on Research and Development in Information Retrieval, New York, NY, USA: ACM, Jul 2020, hlm. 639–648. doi: 10.1145/3397271.3401063.

- [8] V. B. P. Tolety dan E. V. Prasad, “Graph Neural Networks for E-Learning Recommendation Systems,” *International Journal on Recent and Innovation Trends in Computing and Communication*, vol. 11, no. 9s, hlm. 43–50, Agu 2023, doi: 10.17762/ijritcc.v11i9s.7395.
- [9] Q. G. B. W. A. L. Rong Jing, “Paper Recommendation Method based on Attention Mechanism and Graph Neural Network,” *Journal of Electrical Systems*, vol. 20, no. 2, hlm. 88–95, Apr 2024, doi: 10.52783/jes.1101.
- [10] S. Prakki dan M. Daneshyari, “Travel Recommendation System using Graph Neural Networks,” *International Journal of Computing and Artificial Intelligence*, vol. 4, no. 2, hlm. 06–18, Jul 2023, doi: 10.33545/27076571.2023.v4.i2a.66.
- [11] Y. Ma, Z. Ma, Y. Li, H. Gao, dan Y. Xue, “A Project Recommender Based on Customized Graph Neural Networks in Online Labor Markets,” *International Journal Of Computers Communications & Control*, vol. 18, no. 4, Jun 2023, doi: 10.15837/ijccc.2023.4.5173.